

Skill Recorder — 深度分析

5 个 renderer bug 全部修复后的 human-arm 复测 + 失败模式迁移分析

报告日期	2026-05-28
数据源	cold 20260525T084638Z · oracle 20260526T040953Z · human 主轮 20260528T083405Z + 预算重试 20260528T092111Z
Benchmark	WebArena shopping_admin 10 个任务,单 seed
Model	Claude Sonnet 4.6,通过 Claude Code CLI 驱动
Tooling	browse CLI(本地 CDP)+ browsergym/webarena 评估器 · skill-render 0.1.5 · CRX 0.1.24
Pipeline 新增	离线 IndexedDB 解析直读 + 9 个 SKILL.md 全量经过新 renderer 重新渲染

1. Executive Summary

本周修完了之前总结的 5 个产品级 bug。今天用 新的 **offline 重导出 pipeline**(直读 Canary 的 IndexedDB LevelDB)把 9 个 human-arm 录制全部走了一遍当前 renderer,得到一组从源头到 SKILL.md 都包含全部修复的"干净"human SKILL.md,然后对这组 SKILL.md 重跑 human arm。

三个数字

Cold 60.0% → Human 77.8% → Oracle 100.0%。
Human 比昨天 (66.7% = 6/9) 提升 **+11.1 pp**;total cost 也下降 **\$7.55 → \$5.78 (-23%)**,total turns 也下降 **314 → 285 (-9%)**。
Wilson 95% CI 仍然宽:human [45.3%, 93.7%] vs cold [31.3%, 83.2%] 重叠 —— 单 seed 下,7/9 vs 6/9 的统计差异不显著。

但更重要的发现不是数字本身,而是失败原因的迁移:

- 修复前 (5/26):**human-arm 的 3 个失败 (771 / 423 / 694) 原因各异 —— grid 选不中行 / browse fill 误碰 Enter / browse fill 不识别 select。
- 修复后 (5/28):**human-arm 的 2 个失败 (694 / 771) 都不是 renderer 问题 —— 一个是 turn 数不够 (multi-fill 表单天然步骤多),一个是录制范围窄于任务范围 (录的 approve 2 条,任务要全部)。

结论:5 个 renderer / schema 修复方向是对的,但 +1 个 pass 的具体来源 (task 423) 实际是预算原因,不是 renderer 原因 —— 423 在 retry-budget 跑里 44 turns / \$0.85 拿下,远超昨天的 \$1.00 默认上限。

2. Per-task 详细对比 (5/26 vs 5/28)

Task	Cat	Diff	Cold (5/25)		Human 5/26		Human 5/28		Oracle	
			✓	T/\$	✓	T/\$	✓	T/\$	✓	T/\$
webarena.453 Disable Teton hoodie	catalog	easy	✓	47/\$0.63	✓	32/\$0.58	✓	28/\$0.53 -\$0.05	✓	9/\$0.10
webarena.458 Reduce price \$5 (Minerva)	catalog	medium	✓	7/\$0.13	✓	7/\$0.13	✓	11/\$0.16 +\$0.03	✓	8/\$0.11

Task	Cat	Diff	Cold (5/25)		Human 5/26		Human 5/28		Oracle	
			✓	T/\$	✓	T/\$	✓	T/\$	✓	T/\$
webarena.470 Cancel order 302	orders	easy	✓	8/\$0.14	✓	10/\$0.14	✓	10/\$0.14 ±0	✓	7/\$0.08
webarena.496 FedEx tracking #299	orders	medium	✓	24/\$0.55	✓	61/\$1.42	✓	40/\$0.88 -\$0.54	✓	9/\$0.11
webarena.538 Modify order address #299	orders	medium	✓†	51/\$1.34	✓	50/\$1.46	✓	41/\$0.89 -\$0.56	✓	11/\$0.12
webarena.704 Sales report Feb 2023	reports	medium	✓†	8/\$0.14	✓	10/\$0.16	✓	10/\$0.14 -\$0.02	✓	6/\$0.07
webarena.423 Mark Hollister on sale	catalog	hard	✗	51/\$0.85	✗	21/\$0.59	✓ ↑	44/\$0.85	✓	6/\$0.07
webarena.771 Approve positive reviews	reviews	medium	✗	30/\$0.63	✗	71/\$1.88	✗ (原因 变)	40/\$0.75	✓	12/\$0.12
webarena.694 Create Energy- Bulk product	catalog	hard	✗	31/\$0.67	✗	52/\$1.20	✗	61/\$1.44	✓	11/\$0.12
webarena.699 Spring sale price rule	marketing	hard	✗	51/\$1.09	— ‡	— ‡	— ‡	—	✓	9/\$0.10
合计 (excl. 699 for human)			6/10	308 / \$6.18	6/9	314 / \$7.55	7/9	285 / \$5.78	10/10	88 / \$0.99

† Cold trial 704 / 538 是手动覆盖了 CSV 原始 0 (runner_ccc 之前有 pw.Page.url 缓存 bug 导致 validate 失败,修复后手验为通过)。
‡ 699 没有 human SKILL.md —— 设计上跳过,因为这是 native multiselect / cart price rule,原 CRX renderer 结构上无法表达。Human-arm 统计排除此项。

3. 五个产品级 bug — 修复状态对照

本周陆续合入的 5 个 renderer / CRX 修复在今天的 SKILL.md 里实际出现的情况:

#	Bug	修复 commit	在今天的 9 个 SKILL.md 里出现的次数	对今天数字的影响
1	browse fill 默 认按 Enter	6cda994	49 个 fill 里 39 个带 --no-press-enter (80%)	间接 —— 减少 mid-form 误提交,体现在 496/538 cost 各降 ~\$0.5
2	browse fill 写 不了 <select>	3259454	schema 有 'select' action,但旧录制里 element- tag 标记不全,部分仍走 fill 兜底	弱 —— 旧录制无法补救,要 重录或加 buildDrafts 后处 理
3	Grid checkbox 选不 到行	6245bea + c3d6d6a +	12 条 xpath://tr[contains(normalize- space(.), "...")]//... 进了输出,集中在 771	大 —— 771 现在能选对行 了,失败原因从"找不到

#	Bug	修复 commit	在今天的 9 个 SKILL.md 里出现的次数	对今天数字的影响
		1e8c28b		row"迁移到"录制只覆盖了 2 条"
4	pw.Page.url 缓存导致 validate 误判	(runner_ccc 内修)	—	间接 — 538 现在 success=True (yesterday 也已修)
5	CCC 不自动加载 SKILL.md body	976e649	SaveAsSkillDialog 占位符改了,但旧录制 description 字段大多还是 "Dashboard / Magento Admin"(没重写)	本次未生效 — 需要用户重写 description 后才能验证

关键观察:5 个修复方向都对,但只有 #1 和 #3 的效果能在今天的数据里量化看到 — 主要体现在 cost 下降(passing task 也变便宜了),而不是 pass 数上升。 #2 #5 需要重新录制 / 重新编辑才能体现 — 现存 IndexedDB 里的 raw action / description 没有这些信息。

4. 故障模式迁移 — 这才是今天最有信息量的事

用同一组 task 比较两天的失败原因。所有失败都被实际工程师可以采取的行动归类:

Task	5/26 失败原因	5/28 失败原因	能否再下手?
423 Hollister sale	\$1.00 / 40-turn 预算耗尽(底层是 renderer 没充分指导步骤,agent 多走弯路)	PASS @ 44 turns / \$0.85	—
771 Approve reviews	Grid checkbox 选不到行 — rowContext 还没引入	Renderer 修了,Agent 现在能精准选行 + 说 DONE, 但只 approve 了录制里出现的 2 条 (review 352 / 347),task 要求"所有 positive"	需要新机制:SKILL.md 要有"对类似 row 反复应用"的语义,或者 oracle SKILL.md 那种"for each row matching X, do Y"的循环表达
694 Energy- Bulk product	browse fill 误碰 Enter / 各 fill 之间被 form auto-submit 打断	61 turns 顶满 (error_max_turns),agent 没说 DONE。--no-press-enter 修了打断问题,但 form 本身要 7-8 个字段 + size/color attr panel,turn 数天然多	两条路:(a) 提高 default max-turns 到 60+ (b) SKILL.md 做 step-pruning,把 56-action 录制裁到 ~30 关键步

这张表是今天最有产品价值的产出:5 个 renderer bug 修完以后,human 失败的原因不再是"渲染器有问题"。3 个失败 case 各对应一类新问题 — 预算、范围、长度。三个问题各自有清晰的下一步,且都不需要再改 renderer。

5. 反直觉的数据细节

5.1 +1 pass 是 budget 修的,不是 renderer 修的

423 在 5/26 跑用了 21 turns / \$0.59 就退出了,说明 agent 不是卡在"步骤太多",而是提前放弃。但今天用 --max-turns 60 / --max-budget 1.5 重跑就过了。说明 5/26 的失败实际是 runner_ccc 默认预算太紧,把 mid-confidence 的 hard task 错杀了。

这意味着:真正 baseline-level 的 fix 不是 5 个 renderer bug,而是 runner 的默认预算。建议把 runner_ccc 的默认 --max-turns 从 40 提到 60, --max-budget-usd 从 1.0 提到 1.5。这两个参数对 cold/oracle 影响极小(它们本来就远低于上限),但对 human 影响可观。

5.2 Pass 的任务也变便宜了 (-23% total cost)

不只是 423 多一个  —— 整组 human-arm 总 cost 从 \$7.55 → \$5.78,降幅 23%。其中 496 / 538 / 453 三个 task 各降 \$0.05 / \$0.54 / \$0.56。这不是单 seed 噪声 —— 三个都同向降,且降幅集中在 multi-fill 表单类。

这强烈暗示 Bug #1 (--no-press-enter) 起了作用:每个 fill 之前 agent 不再需要"先 snapshot 确认表单没被提交"的防御性 turn。是 renderer 修复在数字上最清晰的痕迹。

5.3 771 的失败模式变了 —— 这是设计层信号

5/26:771 跑了 71 turns / \$1.88 全用在反复"找 Pending review 行"上,最终 budget 耗尽。

5/28:771 跑了 40 turns / \$0.75 提前 DONE 退出,理由是"approved review 352 + 347"。

差异是质变:renderer 修对了,agent 准确执行了录制里的步骤,但录制本身是用户在一页里 approve 了 2 条 review,任务要求是"所有 positive reviews"。录制是采样,任务是总集。SKILL.md 里没有任何信号告诉 agent 这是个 样本 vs. 全集 的关系。

这指向一个 schema 缺失: SkillStep 应该能表达 "for each row matching filter, do action"。Oracle SKILL.md 是用自然语言绕过去的 —— 标题/Background 里写"approve all positive"agent 自己理解。但 CRX 录制路径没有抽象这一层。

5.4 694 现在 cost 反而更高 (61 turns / \$1.44 vs 5/26 的 52 turns / \$1.20)

表面看是退步,但实际是:5/26 跑只跑了 52 turns 就被 \$1.00 cap 打断了,根本没机会跑满;5/28 给到 60 turns / \$1.50,跑满 61 turns 才被 max-turns cap 打断。61 turns 还不够意味着 694 的 56-action 录制本身就需要 LLM 用更多 turns 才能消化 —— 每个 fill / select / click 都对应 1-2 个 CCC turn (LLM 决策 + tool call + 读结果)。

所以 694 不是"renderer 不够好",是"录制行为本身的密度太高,LLM 步骤膨胀系数 1.1-1.2x"。结构性的,renderer 改不了。需要的是 SKILL.md 层 step-pruning(把重复 / 冗余 / 默认值的 step 合并 / 删除),或者 step compression(让 LLM 看到"按图示填写所有字段"这种 high-level instruction 而不是 7 个 fill)。

6. 战略建议

5/26 的报告问过三个战略问题。今天的数据让我重新看了一下:

问题 1 — 5 个 renderer bug 修完后,human 真的会接近 oracle 吗?

部分答案是 "不会,至少不靠 renderer"。Renderer 修对了,但 human → oracle 的 22 pp 差距里,只有 11 pp 通过 renderer + budget 顺手修掉,剩下 11 pp 来自两个全新的瓶颈类别:

- SKILL.md step 数与 LLM turn budget 的关系(694)
- SKILL.md "录的范围 ≤ 任务范围"的语义鸿沟(771)

这两个不是 renderer 问题,是 recording → instruction 的语义转换问题。Oracle SKILL.md 通过自然语言桥接,CRX 录制没桥。要让 human ≈ oracle,需要在 CRX 里加这层桥 —— 比如"录制后让 LLM 看一遍 raw action,生成 high-level 描述"。这是

产品方向选择。

问题 2 — 当下的 CRX 录制路径还有意义吗？

仍然有,但定位变了。原来设想是"用户录一次,输出立刻可用的 SKILL.md"。现实是"用户录一次,输出可以让 agent 执行,但表达能力受限于录制的具体步骤而非任务的语义"。

当前 CRX 对应的产品 fit:

-  **强 fit** — "重复执行同一具体流程"(同一订单同一页面);适合 RPA 类工作
-  **弱 fit** — "执行同一类流程的多个变体"(approve all positive reviews / fill out all draft orders);需要范围扩展
-  **不适用** — "需要判断 / 分支"的流程(if status=Pending then approve);需要条件表达

问题 3 — video-skills 这条线在新数据下值多少？

没变化,见 5/26 报告。但有新观察:771 / 694 这类 "录的范围窄"的问题,video-skills 模式(自然语言 + 视频)反而能避开,因为它从一开始就不是"严格步骤复现",而是"看一段操作,提取意图,生成可推广的 instruction"。

7. 我的推荐 — 不变动 + 一个小改 + 一个中等改

1. **不变动**:暂停继续给 CRX renderer 加修复。5 个 bug 修完后,renderer 已经不是瓶颈。除非之后扩到 shopping(非 admin) 或 forum domain,出现新的 selector 类别。
2. **小改 (~1 小时)**:把 runner_ccc 的默认 budget 提到 `--max-turns 60 --max-budget-usd 1.5`。从今天的数据看,这本身就是 67% → 78% 升级里的主要贡献者。不是 renderer。这是 eval-infra 的 housekeeping,不是产品方向决策。
3. **中等改 (~1 周)**:在 CRX 的 SaveAsSkillDialog 里加一个"录制范围扩展"提示。当 agent 检测到录制内容像是 "为某条 row 做一组操作"(rowContext 出现 ≥1 次),提示用户:"这次录的是对 row X 的操作。任务表述里如果是'对所有满足条件的 row',请在 description 里说明 — 比如'对所有 Pending positive review 重复此流程'。这就是把 §5.3 那个语义鸿沟转给用户填,不增加 renderer 复杂度。

如果上面三件都做,加上 budget 提升,human 大概率到 8/9 (~89%)。要追到 9/9 / 100% 需要解决 694 类的 turn-budget 增长 — 那是 LLM-distillation 的活,不是 CRX 的活。