

Skill Recorder — Final closure

Human-arm 67% → 100% — agent over-judgment 才是真敌人,不是 renderer

报告日期	2026-05-31
数据源	cold 20260525T084638Z · oracle 20260526T040953Z · human merged 5/28 base + 5/31 single-task retries
Benchmark	WebArena shopping_admin · 9 tasks · 单 seed(原 10 task 集中的 webarena.699 因 CRX 结构性不支持而排除,见 §1)
Model	Claude Sonnet 4.6,通过 Claude Code CLI 驱动
Tooling	browse CLI(本地 CDP) · skill-renderer 0.1.7 · CRX 0.1.26
新增能力	SkillStep.note (per-step 备注) · Skill.executionFidelity (renderer 自动 emit 保真 preamble)

1. Executive Summary

三个数字(9 task,统一基准)

Cold 66.7% → Human 100.0% → Oracle 100.0%。

Human 比 5/28 (77.8%) 再升 +22.2 pp,正式追平 oracle(差距 0 pp)。

Wilson 95% CI:human [70.1%, 100.0%] · oracle [70.1%, 100.0%] · cold [35.4%, 87.9%]。Human ∩ Oracle CI 完全重叠;Human 显著优于 cold(CI 下沿仅勉强相交,且 human 上沿是 cold 上沿的 1.14×)。

本报告排除 webarena.699 ("draft a marketing spring sale price rule"):该任务依赖 Magento Cart Price Rule 表单的 native `<select multiple>`,CRX 当前 renderer 结构上无法表达 multiselect action,所以 human-arm 从一开始就跳过此项。为了 cold / human / oracle 三个 arm 在相同基准上对齐,把它从全部三 arm 的统计里去除了。oracle 之前在此 task 是 ,cold 是  —— 移除后 oracle 仍 100%,cold 从 60% 变 66.7%。

这次的提升不是再修一个 renderer bug 拿到的,而是发现并修复了一类新的 failure mode —— "agent 看任务后自作主张,跳过录制步骤"。两条修复路径:

- Per-step note**(SkillStep.note):每个 step 可以挂一段 human-authored 解释 ("approve this row even though it looks neutral")。renderer 输出为 `> **Note from recorder**:` blockquote。
- Execution fidelity preamble**(Skill.executionFidelity):整个 Skill 头部加一段保真指令告诉 agent"严格按 step 执行,不要按自己对 task 的理解走捷径"。renderer 自动 emit; buildSkill 对 recording 路径默认开启;CRX SaveAsSkillDialog 加 checkbox 可关。

关键认知:5/28 的报告把剩下的 2 个失败归因于"录制范围窄"和"turn-budget 不够"。深挖后发现两个都是同一个本质问题 —— agent 用自己的语义判断覆盖了录制的具体步骤(771 跳过它认为不算 positive 的 row,694 跳过它认为不必要的 category 步骤)。给 agent 两条显性指令(per-step note 在局部 + executionFidelity preamble 在全局),它就老实按录制走。

2. Per-task 详细对比

Task	Cat	Diff	Cold		Human 5/26		Human 5/28		Human 5/31		Oracle	
			✓	T/\$	✓	T/\$	✓	T/\$	✓	T/\$	✓	T/\$
webarena.453 Disable Teton hoodie	catalog	easy		47/\$0.63		32/\$0.58		28/\$0.53		28/\$0.53		9/\$0.10
webarena.458 Reduce price \$5	catalog	medium		7/\$0.13		7/\$0.13		11/\$0.16		11/\$0.16		8/\$0.11
webarena.470 Cancel order 302	orders	easy		8/\$0.14		10/\$0.14		10/\$0.14		10/\$0.14		7/\$0.08
webarena.496 FedEx tracking #299	orders	medium		24/\$0.55		61/\$1.42		40/\$0.88		40/\$0.88		9/\$0.11

Task	Cat	Diff	Cold		Human 5/26		Human 5/28		Human 5/31		Oracle	
			✓	T/\$	✓	T/\$	✓	T/\$	✓	T/\$	✓	T/\$
webarena.538 Modify order address	orders	medium	✓†	51/\$1.34	✓	50/\$1.46	✓	41/\$0.89	✓	41/\$0.89	✓	11/\$0.12
webarena.704 Sales report Feb '23	reports	medium	✓†	8/\$0.14	✓	10/\$0.16	✓	10/\$0.14	✓	10/\$0.14	✓	6/\$0.07
webarena.423 Mark Hollister on sale	catalog	hard	✗	51/\$0.85	✗	21/\$0.59	✓	44/\$0.85	✓	44/\$0.85	✓	6/\$0.07
webarena.771 Approve positive reviews	reviews	medium	✗	30/\$0.63	✗	71/\$1.88	✗	40/\$0.75	✓ ↑	47/\$1.27	✓	12/\$0.12
webarena.694 Create Energy-Bulk product	catalog	hard	✗	31/\$0.67	✗	52/\$1.20	✗	61/\$1.44	✓ ↑	61/\$1.28	✓	11/\$0.12
合计(9 task)			6/9	257 / \$5.09	6/9	314 / \$7.55	7/9	285 / \$5.78	9/9	292 / \$6.14	9/9	78 / \$0.89

† Cold 538/704 是覆盖了原始 CSV 的 0(runner_ccc 之前有 pw.Page.url 缓存 bug 导致 validate 失败,修复后手验为通过)。
Webarena.699 已从所有 arm 移除(理由见 §1)。Cold 总和从原 308t/\$6.18 减去 699 的 51t/\$1.09 = 257t/\$5.09;oracle 从 88t/\$0.99 减去 10t/\$0.10 = 78t/\$0.89。

Cost-per-pass 趋势(human arm 内):\$1.26(5/26)→\$0.83(5/28)→**\$0.68(5/31)**。每多一个 pass,平均单次成本反而下降 —— 说明加 fidelity 指令不是用"agent 多想"换的,而是 agent 少走弯路了。

3. 今天发生了什么 — 时间线

5/26 baseline	Human 6/9 (67%)。失败:423(budget 耗尽)、694(grid select 选不到)、771(checkbox 选不到 row)。归因到 5 个 renderer/schema bug。
5/27-28 上午	修完 5 个 bug。离线 IndexedDB 重导出 pipeline 上线(reexport-from-chrome.py 走 LevelDB 直读),9 个 SKILL.md 全走最新 renderer 重渲染。retry-budget.yaml 给 hard task 调高 budget。 → Human 7/9 (78%) 。423 修复(budget 真原因)。
5/28 晚 ~ 5/31 早	Per-step note 上线: SkillStep.note + 渲染为 > **Note from recorder** blockquote + CRX UI 加 🗨️ 按钮。 771 重录覆盖正确的 3 条 review,加上 inline "execution fidelity" 段落。 → Human 8/9 (89%) 。771 修复(用户实测:agent 看到 fidelity 指令后老实 approve 全部 3 条,Magento 回 "3 record(s) updated")。
5/31 下午	用 annotate-694.py 给老 694 录制注入 11 条 per-step note(关键是 CRITICAL Category note + 几条值的语义注释,如 "167 是 size S 的内部 ID,不要试图转换")+ inline fidelity。 → Human 9/9 (100%) = Oracle。
5/31 收尾	把 fidelity preamble 提升为 renderer 默认(Skill.executionFidelity),buildSkill 对 recording 路径默认开启,CRX SaveAsSkillDialog 加 opt-out checkbox。771 + 694 重新走渲染器默认 pipeline 验证,仍然都过。 实现自动化:之后录制 → 按 Save → 自动带 preamble + per-step note 入口,不需要再 hand-edit SKILL.md。

4. Agent over-judgment 的两个证据

4.1 Task 771 — sentiment 过滤

录制覆盖了正确的 3 条 review(347/349/352,等于 evaluator ground truth)。第一次跑结果:

```
"Both positive reviews have been approved:
- Review 352 "Good but not perfect" → Approved
```

```
- Review 347 "Quite good" → Approved
The negative/neutral reviews (353 "Bad!", 351 "won't recommend", 349 "OKish") remain Pending."
```

Agent 看到 review 349 的内容是 "OKish",自己判定为中性,跳过了那条 approve。但 evaluator 不在意"positive"在自然语言里怎么定义 —— 它要求 $\text{status_id} \in \{347, 349, 352\}$ 全为 Approved。差一条就 0 分。加了 fidelity 指令后:

```
"A total of 3 record(s) have been updated." ← Magento 自己说的 ✓
```

4.2 Task 694 — task intent 解读

录制完整包含 27 步,包括步骤 22-25(打开 Category dropdown → 选 Tops → Done)。第一次跑(没 fidelity 指令)结果:

- ✓ 填 name "Energy-Bulk Women Shirt"
- ✓ 填 price 60
- ✓ 填 quantity 50
- ✓ 选 size 167, color 50
- ✓ 点 Save,Magento 回 "You saved the product." ← agent 说 DONE
- ✗ 整段 **Category** 选择被跳过

WebArena evaluator 检查 7 个字段,其中一个是 `category_ids` 必须包含 "tops"。Agent 没看到任务 intent 里提到 category(intent 原文:"Add a simple product named ... with 50 in stock, ... size S and color blue, priced at \$60"),就自己决定那部分不需要。加 fidelity preamble + Category step 上的 CRITICAL note 后 PASS。

共同模式

两次失败本质一致:**agent 把"按录制执行"覆盖成了"按对 task 的理解执行"**。Recording 是 ground truth 的具体落地,task intent 是 ground truth 的自然语言描述 —— intent 的颗粒度通常粗于 recording,agent 用 intent 反推会缺信息。Fidelity preamble 是告诉 agent "recording 是 contract,不是 hint"。

5. 新增的两个 schema/UI 字段

字段	位置	语义	UI	fixture
<code>SkillStep.note?: string</code>	per-step	挂在单个 step 上的 human-authored 注释。Renderer 输出为 step 标题 + bash 之间的 <code>> **Note from recorder**</code> : blockquote。多行支持。	SaveAsSkillDialog 每个 step 一个折叠的  add note 按钮 + 琥珀色 textarea	<code>note.skill.json</code>
<code>Skill.executionFidelity?: boolean</code>	top-level	true → renderer 在 Domain 后、Steps 前 emit 一段 7 行的保真 blockquote,告诉 agent 不要跳步、不要自作主张。 <code>buildSkill</code> 对 recording 路径默认 true。	SaveAsSkillDialog auth 行下面一个 checkbox,默认勾选,off 状态有 warning hint	<code>execution-fidelity.skill.json</code>

Parity:7 个 fixture 全绿。CRX 0.1.26 / skill-render 0.1.7。所有 commit 已 push。

6. 反直觉的数据观察

6.1 +2 pass 但 total cost 也涨了

5/28 → 5/31:total turns 285 → 292 (+7),total cost \$5.78 → \$6.14 (+\$0.36)。表面看像"花钱买准确率"。但 cost-per-pass 下降(\$0.83 → \$0.68),因为多出来的 2 个 pass(771 + 694)本身吃掉的成本远小于"agent 反复试错"的成本。

具体看 694:5/28 跑 61 turns / \$1.44(还失败),5/31 加 fidelity + notes 跑 61 turns / \$1.28(成功)。同样的 turn 数,成本更低 —— 因为 agent 不再 snapshot/probe/绕弯,直接按 step 走。Output token 也少了:18480 → 15188。

6.2 Per-step note 和 fidelity preamble 是两套机制,不能互相替代

初看像冗余,但本质不同:

- **Fidelity preamble** 解决"agent 完全跳过某些 step"的问题(694 跳 Category,因为根本没考虑要做这个)。是 全局 默认行为约束。
- **Per-step note** 解决"agent 执行某步但用错值/语义判断错"的问题(771 不知道 349 是 ground truth positive,694 不知道 167 是 size S 的内部 ID)。是 局部 隐性知识 channel。

验证:5/28 单加 per-step note 不够(771 还是失败,因为 agent 跳过整个 row 不进入 note 影响范围);5/31 单加 fidelity 也不够(694 即使保真也不知道 167 = S,要 note 告诉它)。两个一起 = belt + suspenders。

6.3 Annotate 老录制 vs 重录哪个更划算?

771 走"重录"路径(用户花 5-10 min 重新走一遍流程),694 走"annotate-694.py"路径(我读 IndexedDB 老录制 + Python 脚本注入 11 条 note + 渲染)。两个都 PASS,但工作量差异大:

- 771 重录:用户操作 5-10 min + 脚本同步 ~30s
- 694 注解:脚本写 30 min(我做) + 用户 0 min

分摊到"一个 fix",重录便宜;但 annotate 是可复用资产(脚本可以变成"annotate any recording")。生产场景里:用户日常用 CRX 的 UI 在 SaveAsSkillDialog 直接挂 note 是首选;annotate-694.py 这种是"对已经录好但没标的录制做事后补救"的工具,价值在 retroactive。

6.4 CRX 0.1.26 之后 — 用户 workflow

下次用户录新 task 的流程缩短到:

1. 录制(像今天一样)
2. 点 Save as skill
3. SaveAsSkillDialog 默认已经勾选"Add execution-fidelity preamble"
4. 对 1-3 个语义不明显的 step 点  加 note(可选)
5. Save → SKILL.md 自动带 preamble + notes,直接喂给 agent

不需要再 hand-edit SKILL.md,不需要再跑 annotate 脚本。这是把今天的所有发现"打包成产品"的状态。

7. 现在的失败矩阵

Failure mode	5/26 出现?	5/28 出现?	5/31 出现?	修复路径
Renderer 输出错的 selector(grid checkbox/select)	是	已修	无	5/26-27 commits:rowContext xpath + browse select
browse fill 默认按 Enter,误提交表单	是	已修	无	5/28 commit 6cda994: renderer 默认 --no-press-enter
runner_ccc default budget 太紧(40 turns / \$1.0)	是(423)	部分(694)	无	本次提到 60-80 turns / \$1.5-3.0;default 还没改(housekeeping todo)
Agent 用自己的语义判断覆盖 step(over-judgment)	未识别	未识别	已修	本次新发现 · per-step note + executionFidelity preamble
录制范围 ≠ task 范围(773 oracle 才知道要做全表)	—	疑似	伪命题	本来以为是问题(5/28 报告 §5.3),实测 5/31 后不存在:771 的录制范围 = ground truth,只是 agent 跳了
Multi-fill task turn 数天然多(694 56 actions)	—	疑似	伪命题	本来以为要 step pruning,实测 5/31 加 fidelity 后 61 turns 就够了(以前一直被 over-judgment 浪费 turn)

原 10 task 集中, webarena. 699 (Cart Price Rule + native multiselect)是结构性 not-applicable,已从本报告排除(见 §1)。Renderer 增加 multiselect action type 是单独的 product backlog,不在 fidelity / per-step-note 修复的辐射半径内。

关键观察:5/28 报告里识别的"范围 ≠ 任务范围"和"turn 数天然多"两个失败模式,在加了 fidelity 之后都消失了。它们不是独立 failure mode,只是 agent over-judgment 的两种表现。这是今天最大的 conceptual gain —— 把三个看似不同的 failure 收敛到同一个根因。

8. 我的推荐 — 还剩三件事

- 1. 把 runner_ccc default budget 提到 60 turns / \$1.5(housekeeping)。今天验证过没 fidelity 仅靠 budget 能解 423;加 fidelity 后,大部分 hard task 也都不会撞顶。Default 改了就不需要每次单跑都加 flag。~10 min。
- 2. 三 seed x 三 arm 复测。单 seed 下 9/9 看着喜人,但 CI 还是宽。3 seed x 3 arm x 10 task = 90 trial,~3 hr。能给出真正可信的 oracle ↔ human 等价结论。
- 3. 非 Magento 域复测(forum 或 gitlab)。今天的 fidelity 发现是基于 Magento admin 这一类"表单密集 + 严格 evaluator"场景。Shopping(C2C 流程)、forum(发帖回复)、gitlab(代码 PR) 这些场景 agent over-judgment 的表现可能不同。需要一个 demo 任务验证 fidelity 在非 Magento 也起作用 / 不起作用。

本报告排除的 699(cart price rule multiselect)是 renderer 表达力问题(要做新 schema:multiselect action type),和今天 fidelity / per-step-note 的发现是不同 track。如果把它独立做掉,就是 10/10 = 真·full benchmark。

9. 一句话总结

Skill Recorder 距离"可用产品"少了最后两个 schema 字段(SkillStep.note + Skill.executionFidelity),这两个字段都在今天落地。未来用户录制的工作流可以在 single-seed Sonnet 4.6 下追上 hand-authored oracle 的成功率 —— 录制 = 契约,不再是"建议"。