

Skill Recorder Evaluation — Cold Baseline 第一轮

在 WebArena shopping_admin 上用 Claude Code CLI 跑 10 个任务 / 单 seed / 无 SKILL.md

报告日期	2026-05-25
运行 ID	20260525T084638Z
Runner	src/runner_ccc.py (CCC 路径,非 AgentLab+API)
Backbone	Claude Code CLI, --model sonnet (claude-sonnet-4-6)
Benchmark	WebArena — shopping_admin (Magento 后台) 单服务
任务数	10(来自 eval/tasks/selection.yaml)
Arms / Seeds	仅 cold arm,seed=0(1 个 seed,作为 baseline 第一轮)

Executive Summary

裸 Claude Code(无录制 SKILL.md)在 10 个 WebArena shopping_admin 任务上的成功率为 **5/10 = 50%**,wall-clock 总 30 分钟,subscription 用量约 **\$6.18**(若按 sonnet-4-6 API 公开定价计)。这个数字

- 超过事先设计的 **sanity** 上限 **30%** — 说明任务集对 frontier 模型偏简单,Skill Recorder 演示价值的 delta 被压缩;
- 失败集中在 **5 个状态变更复杂或需要多步验证** 的任务,是 Oracle / Human arm 杠杆最大的样本;
- 暴露了 cold arm 的典型病:CCC 在没演示引导时倾向于**提前自报 DONE**(704 任务 8 turns 就 DONE,实际报表压根没生成)。

方法学

3-arm 设计(本轮只跑了第 1 arm)

Arm	含义	本轮跑了?
Cold	无 SKILL.md,纯 Claude Code + browse 工具	✓
Oracle	手写 / 论文 trace 蒸馏出的"理论上限"演示	未跑
Human	用 Skill Recorder 扩展真录一份的演示	未跑

Runner 链路

```
Playwright 起 Chromium (--remote-debugging-port=9222)
↓
browsergym/webarena GenericWebArenaTask.setup(page) → 登录 admin/admin1234 + 导航 sta
```




每个 trial 之间, ./docker/setup-webarena.sh reset shopping_admin 把 Magento DB 退回 fixture 初态,防止前一 trial 的 mutation 污染评分。

结果总表

任务	难度	评估方式	Turns	Wall (s)	Cost (\$)	CCC 自报	Evaluator
webarena.453 — Disable Teton Pullover Hoodie	easy	program_html	47	202	0.633	✓	✓ 1.0
webarena.458 — Reduce price of this product by \$5	medium	program_html	7	61	0.129	✓	✓ 1.0
webarena.470 — Cancel order 302	easy	program_html	8	47	0.144	✓	✓ 1.0
webarena.496 — Update order #299 FedEx tracking number	medium	program_html	24	134	0.546	✓	✓ 1.0
webarena.538 — Modify address of order #299	medium	program_html	51	273	1.344	⚠ max-turns	✓ 1.0
webarena.771 — Approve positive reviews	medium	program_html	30	209	0.625	✓	✗ 0.0
webarena.423 — Mark all Hollister shirts on sale	hard	program_html	51	307	0.854	⚠ max-turns	✗ 0.0

任务	难度	评估方式	Turns	Wall (s)	Cost (\$)	CCC 自报	Evaluator
webarena.704 — Generate sales order report (last month)	medium	url_match + program_html	8	53	0.137	✓	✗ 0.0
webarena.694 — Create simple product "Energy-Bulk Women Shirt"	hard	url_match + program_html	31	182	0.671	✓	✗ 0.0
webarena.699 — Draft 20% spring-sale price rule	hard	url_match + program_html	51	318	1.091	⚠ max-turns	✗ 0.0
合计 10 trials			308	1785	6.184	8/10 self-OK	5/10 = 50%

Turns 分布(柱状)



蓝色 = evaluator 评成功;红色 = 失败。 max-turns 50 上限对应满格柱状(51 因 turn 计数器从 0 起,实际 50 turns 用尽)。

关键发现

1. Cold 50% > 设计 sanity 上限 30%。

按 docs/design-followups.md §2 的诊断手册,cold > 30% 意味着任务集对 frontier 模型(此处是 Claude Sonnet 4.6)偏简单,Skill Recorder 演示价值的最大可能 delta 被压缩。可行的处置: 把 453 / 458 / 470 这三个 cold 顺利通过的任务从 selection 里换掉,改成 WebArena 中其它 22 个 shopping_admin mutation template 里更难样本,重跑 cold 让基线落回 [5%, 30%] 区间。

2. 704 是教科书级的 "agent 假阳性 DONE"。

任务"今天是 3/15/2023,生成上月销售订单报表"。CCC 只用 8 turns 就回 "DONE",但 evaluator 检查 URL+page 状态时报 0.0 — 它根本没真正进入 Reports → Sales → 选择日期范围 → 点 "Show Report" 的链路,就基于看到的页面"以为做完了"。这是 cold arm 在多步骤、隐式校验型任务上的典型病,SKILL.md 引导下应该被消除 — 如果 oracle / human arm 在 704 上能拉到 1.0,这就是 Skill Recorder 产品的硬核卖点。

3. 538 是"做完了但没说 DONE 被砍"的边界。

任务"改 order #299 的 shipping address"。CCC is_error=True (撞 --max-turns 50 被砍),但 evaluator 报 1.0 — DB 里地址确实改对了。说明 CCC 完成了 mutation 但没及时报 DONE。如果把 max-turns 调到 60-80,这个任务在 cold arm 也是"自然成功",cold 真实成功率可能更高(6/10)。这对 baseline 数字稳定性是个警示。

失败案例聚类

5 个失败任务可按瓶颈类型分组:

瓶颈类型	例子	SKILL.md 应有的帮助
多步验证	704 (报表生成)、771 (审核流)	明确告诉 agent "show report" 按钮在哪、什么状态算"approved"
多 section 表单	694 (Create product)、699 (Price rule)	列清楚必填字段顺序、避免漏 SKU / from-to 日期
Bulk 操作	423 (Mark all on sale)	展示 filter → 全选 → bulk-edit 的"三段式"

成本 / 时间

	值	单位
Wall clock 总耗时	1785	秒(≈ 30 分钟)

	值	单位
其中 docker reset 开销	~250	秒 (10 × 25s)
每 trial 平均 wall-clock	179	秒
每 trial 平均 turns	30.8	轮
每 trial 平均 cost	\$0.62	(sonnet)
本轮总 cost	\$6.18	
推算 90 trial(3 arm × 3 seed)	~\$55	(若 oracle/human 与 cold 同量级)

下一步建议

三条候选路径,按落地难度排序:

1. **B 路径:先写 oracle 看 delta。** 对 5 个 cold 失败任务(771/423/704/694/699)各手写一份 SKILL.md(估 3-4 小时人工 + \$2-3 跑成本),只跑 oracle × 5 trial。如果 oracle 能拿到 4-5/5(80-100%),Skill Recorder 故事就有数字支撑。**推荐先做这条。**
2. **A 路径:收紧任务集再跑 cold。** 把 453/458/470 换成更难的任务,让 cold 落回 10-30%,headroom 拉满,但要重跑一次 cold(\$6)。
3. **C 路径:直接跑全 90 trial。** 加 oracle/human + 3 seeds,\$40-50 + 6h。等 oracle delta 验证后再上。

另一个不需要决策的小修:把 `--max-turns` 从 50 提到 70,538 这类"做完了没及时报告"的边界会消失,baseline 数字更稳。代价:每 trial 上限多 ~20 turns,极端情况下成本上限 +40%,实际平均提升预计 <10%。

附录:原始 CSV 链接

所有 trial 的完整 row 数据:

`eval/results/runs/20260525T084638Z/runs.csv`

每个 trial 的 CCC 原始 JSON 输出(含 model usage / per-turn tokens / 完整 result 字符串):

`/var/folders/.../ccc-trial-<task>-cold-seed0-<hash>/claude-output.json`

(workdir 在 macOS tempdir 下,trial 结束后保留供 debug)