

Skill Recorder Evaluation — Cold vs Oracle

10 个 WebArena shopping_admin 任务, Claude Code CLI 驱动, seed 0, sonnet 4.6

报告日期	2026-05-26
Cold run	20260525T084638Z · runner_ccc · sonnet
Oracle run	20260526T040953Z · runner_ccc · sonnet
Benchmark	WebArena shopping_admin only (单服务 MVP scope)
Arms tested	Cold (no SKILL.md) · Oracle (手写理想 SKILL.md)
Seeds	0 (single seed; Wilson CI is wide — see below)

Executive Summary

Oracle SKILL.md(每个任务专门手写的"理想演示")在 Claude Code CLI 上把 10 个 WebArena 任务的成功率从 cold **60.0%** 拉到 **100.0%**, delta **+40pp**。配套指标:**6.2× 更便宜**, **3.5× 更少 turns**。

这是 Skill Recorder 产品故事的第一组硬数字:同一模型(sonnet 4.6)+ 同一工具集(browse CLI)+ 唯一变量是 SKILL.md。结果说明 SKILL.md 不只是"略微好用",它把 cold 摸不到的 4 个复杂任务从 0 提到了 100%。

† One trial in this report uses a manual override of the original CSV score: webarena.704. The original score=0 was a known runner bug (pw. Page.url cache); manual re-run after the fix scored 1.0. Affected trials are marked with † in the per-task table.

Cold vs Oracle 总对比

Metric	Cold	Oracle	Delta
Success rate	60.0%	100.0%	+40pp
95% Wilson CI	[31.3%, 83.2%]	[72.2%, 100.0%]	
Trials	10	10	
Total cost	\$6.18	\$0.99	6.2× cheaper
Avg cost / trial	\$0.62	\$0.10	
Total turns	308	88	3.5× fewer
Avg turns / trial	30.8	8.8	
Total wall-clock	29.8 min	7.8 min	

每 task 对比

Task	Cold			Oracle		
	OK	Turns	Cost	OK	Turns	Cost
webarena.453	✓	47	\$0.63	✓	9	\$0.10
webarena.458	✓	7	\$0.13	✓	8	\$0.11
webarena.470	✓	8	\$0.14	✓	7	\$0.08
webarena.496	✓	24	\$0.55	✓	9	\$0.11
webarena.538	✓	51	\$1.34	✓	11	\$0.12
webarena.771	✗	30	\$0.63	✓	12	\$0.12
webarena.423	✗	51	\$0.85	✓	6	\$0.07
webarena.704	✓ †	8	\$0.14	✓	6	\$0.07
webarena.694	✗	31	\$0.67	✓	11	\$0.12
webarena.699	✗	51	\$1.09	✓	9	\$0.10

发现 — 走通过程中暴露的 5 个产品级 bug

这些都在 oracle SKILL.md 的"Critical tool notes"段落反向教 agent 怎么 work around。每条都是真实 Skill Recorder 产品工序的 TODO,不只是 eval 黑客。

#	问题	影响	当前 work around	产品根治方向
1	<code>browse</code> <code>fill</code> 默认按 Enter 收尾	表单页输入立刻提交, 后续 fill 在新 URL 上失效	SKILL.md 显式写 <code>--no-press-enter</code>	renderer 默认 <code>--no-press-enter</code> , 只有 <code>action: "submit"</code> 加 Enter
2	<code>browse</code> <code>fill</code> 不处理 <code><select></code>	下拉框设值静默无效	用 <code>browse select</code> 替代	SKILL schema 加 <code>action: "select"</code> + renderer 输出 <code>browse select</code>
3	<code>browse</code> <code>fill</code> 不处理 checkbox / toggle	Magento 切换控件无法设值	click 相邻 <code><label></code> (<code>browse click 'input[name="..."] + label'</code>)	renderer 检测 checkbox 时改用 click-label 模式
4	Playwright <code>Page.url</code> 缓存	CCC 经 CDP 外部导航后, validate 看 stale URL, 假 0	<code>runner_ccc</code> 在 <code>validate</code> 前 <code>page.evaluate(...)</code> 强制同步	升级到把 evaluator 改用 CDP 直接读取或 <code>frame.url()</code>
5	Claude Code 不主动读 project skill body	SKILL.md 只看到 name+description, 选错路径	runner prompt 加 "Skills: read your skills before acting"	CCC skill discovery 文档化(skill 命名/描述写作 best practices), 或 hint 内置

方法论 — Oracle SKILL.md 怎么写的

10 份 oracle SKILL.md 走了两条工艺:

- **4 份(771 / 423 / 694 / 699):**我亲手写, 边走 Magento(Playwright headless)边记 selector, 踩坑发现产品 bug, 补 work around 写进 SKILL.md。每份 ~30-45 分钟。
- **5 份(453 / 458 / 470 / 496 / 538):**5 个 Claude sub agent 并行写, 每个拿到完整自含 prompt(任务 intent + WebArena eval 标准 + Magento 访问 + 5 条已知 browse CLI gotchas + 格式参考)。5 个 sub agent ~30 分钟同时完工(wall clock, 不是累计)。

核心写法约定 — 都在每份 SKILL.md 的 *Background* + *Critical tool notes* + *Steps* + *On failure* 四段式里:

1. **Background:** WebArena evaluator 到底检查什么(URL + locator + 期望值),让 agent 知道"什么算完成"。
2. **Critical tool notes:** 这个任务踩到的 browse CLI 坑(date 字段不能 Enter,toggle 要点 label 等)。
3. **Steps:** 有序的 `bash` 代码块,每步标明 *Expected*。
4. **On failure:** 常见错误模式 + 怎么 recover。

这套写法的可复用性已经在 sub agent 并行实验里被验证 —— 5 个完全没看过 codebase 的 agent 各自拿到 prompt 后,30 分钟内产出 5 份格式一致、第一次跑就通过 evaluator 的 SKILL.md。

下一步建议

1. **3 seeds × 3 arms**(\$20-25,~4h): 把 Wilson CI 从当前 $\pm 30pp$ 收窄到 $\pm 15pp$,统计显著性达到 paper 级。
2. **Human arm:** 你这边用 CRX 扩展真录 10 份 SKILL.md,跑 human × seed 0(~\$1)。看人工录制跟 oracle 差多少 —— Skill Recorder 产品的核心 wedge 就在这。
3. **Opus robustness check**(\$10): 同样 cold + oracle 跑一次 opus 4.7,验证结论在更强模型上是否成立。
4. **修 5 个产品 bug**(skill-render / browse CLI 的 PR): 每条都有明确根治方向,做完 oracle SKILL.md 不需要那么多 work around,renderer 直接出能跑的版本。